

物理情報ニューラルネットワークによる2D熱伝導 方程式の求解：性能比較分析

データ駆動型、物理情報活用型（PINN/PENN）、および伝統的数値解法（差分法）の精度と計算コストに関する定量的評価



ML-only (データ駆動型NN)

$\mathcal{L}_{\text{PDE}}$

PINN (物理情報NN)



PENN (物理埋込型NN)



Finite Difference (差分法)

評価の舞台：2D熱伝導問題

支配方程式 (PDE)

$$\frac{\partial u}{\partial t} = \alpha \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right)$$

領域: $(x, y) \in [0, 1]^2$, $t \in [0, 1]$

熱拡散係数: $\alpha = 0.1$

境界条件 (BC)

ディリクレ境界条件

$u = 0$ (全ての境界上で)


初期条件 (IC)

$$u(x, y, 0) = \sin(\pi x) \sin(\pi y)$$

解析解 (Ground Truth)

この問題には、性能評価の基準となる厳密な解析解が存在する。


$$u(x, y, t) = \exp(-2\alpha\pi^2 t) \sin(\pi x) \sin(\pi y)$$



4つの挑戦者：物理知識の活用スペクトラム

純粋なデータ

純粋な物理アルゴリズム



ML-only
(データ駆動型NN)

物理法則を考慮せず、入出力データのみから関係性を学習するブラックボックス。

PINN
(物理情報NN)

損失関数に物理法則（PDE残差）を組み込むことで、物理的な妥当性を促す。

ソフトな制約

PENN
(物理埋込型NN)

ネットワークアーキテクチャ自体に物理法則を埋め込み、解の構造を強制する。

ハードな制約

Finite Difference
(差分法)

物理法則を離散化し、アルゴリズムとして直接的に解を計算する古典的手法。

アプローチ 1 & 2 : 標準MLPを基盤とする解法


ML-only (教師あり回帰)

- **コンセプト:** PDEを無視し、純粋な関数近似問題として扱う。
- **モデル:** MLP (width=64, depth=4)
- **学習データ:** (x, y, t) と正解 u のペアからなる大規模データセット (8,000点) が必要。
- **損失関数:** $\text{Loss} = \text{MSE}(u_{\text{pred}}, u_{\text{true}})$



PINN (物理情報)


- **コンセプト:** 正解データなしで、物理法則自体を教師として学習。
- **モデル:** MLP (width=64, depth=4) (ML-onlyと同一)
- **学習点:** 物理法則を評価する内部の点 (12,000点)、初期条件点 (2,048点)、境界条件点 (2,048点)。
- **損失関数:** $\text{Loss} = w_{\text{pde}} * \text{Loss_PDE} + w_{\text{ic}} * \text{Loss_IC} + w_{\text{bc}} * \text{Loss_BC}$




アプローチ 3：物理を構造に埋め込むPENNN

物理的洞察を活用し、解の構造をネットワークに強制する。

- **Ansatz (解の仮定)**: 境界条件を常に満たすように、解を $u(x, y, t) = \sin(\pi x)\sin(\pi y) * a(t)$ と仮定。
- **問題の単純化**: これにより、ネットワークが学習すべきは、空間に依存しない1次元の時間関数 $a(t)$ のみとなる。


$$\frac{\partial u}{\partial t} = \alpha \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right)$$


Ansatzを適用



$$\begin{aligned} \frac{da}{dt} + 2\alpha\pi^2 a(t) &= 0 \\ a(0) &= 1 \end{aligned} \quad t$$

$a(t)$ を学習するための、より小型なネットワーク。

PENN_Heat_2D (内部ネットワーク: width=32, depth=2)



アプローチ 4：ベースラインとなる伝統的数値解法（差分法）

コンセプト

空間と時間を格子状に離散化し、物理法則に基づいて時間ステップごとに解を更新していくアルゴリズム。

手法



時間に陽的、空間に2次中心差分を用いたスキーム。

計算プロセス

1. 空間 (x, y) と時間 t をグリッドに分割。
 - グリッドサイズ: $nx=51, ny=51, nt=4001$
2. 初期条件 $U[t=0]$ を設定。
3. 時間ステップ n から $n+1$ へ、差分化された方程式を用いて U を逐次計算。


特性

- 解は離散的な格子点上でのみ得られる。
- 格子点以外の任意の点 (x, y, t) での値を求めるには、補間（この実装では三重線形補間）が必要となる。



2次中心差分ステンシル


各解法による解の比較 (t=1.0) - 一見すると全て良好な結果



時刻 $t=1.0$ において、全ての解法が解析解の全体的な構造（中央にピークを持つ滑らかな分布）を捉えていることが視覚的に確認できる。


真の解との誤差比較 (t=1.0) - 精度に数桁の差が明らかに

Error ML-only




誤差スケール: $O(10^{-2})$

Error PINN




誤差スケール: $O(10^{-3})$

Error PENN



誤差スケール: $O(10^{-5})$

Error FD numeric



誤差スケール: $O(10^{-5})$

ML-onlyの誤差は ' $O(10^{-2})$ ' であるのに対し、PENNと差分法の誤差は ' $O(10^{-5})$ ' と、その差は1000倍に達する。物理的制約を組み込むことで、精度が劇的に向上することが一目瞭然である。


定量的評価：精度（MSE）と計算コスト

手法 (Method)	平均二乗誤差 (MSE)	学習/計算時間
ML-only	1.608e-04	2.7 s
PINN	4.381e-06	59.1 s
PENN	1.695e-08	4.2 s
FD numeric	2.707e-08	0.1 s

- **最高精度:** PENNと差分法が同等の極めて高い精度（ $\text{MSE} \sim 10^{-8}$ ）を達成。
- **学習コスト:** PINNは高階微分の計算により、学習時間が突出して長い（59.1s）。
- **計算速度:** 差分法は伝統的なアプローチでありながら、解の計算自体は非常に高速（0.1s）。
- **バランス:** PENNは、差分法に匹敵する高精度を、ML-only並の高速な学習時間で実現している。

推論速度の比較：学習済みモデルの評価効率

評価条件: 差分法で用いたグリッド（`51x51x4001`点、合計約1000万点）全てに対する予測時間を計測。



PENNの推論速度が圧倒的に速い。これは、ネットワークサイズが格段に小さい（width=32, depth=2）ことに起因する。

ML-onlyとPINNは、より大きなネットワーク（width=64, depth=4）を使用するため、評価に時間がかかる。

応用上、多数のクエリへの高速応答が求められる場面では、PENNの優位性が際立つ。

（注: 差分法の推論は、事前計算されたグリッドからの補間に相当し、そのコストプロファイルは異なるため、ここではNNベースの手法を直接比較）

各解法のトレードオフ サマリー

手法	精度 (Accuracy)	学習コスト (Training)	推論速度 (Inference)	物理知識の活用
ML-only	低	高速 / 高データ依存	遅い	なし (ブラックボックス)
PINN	中	非常に遅い	遅い	損失関数 (ソフト制約)
PENN	高	高速 / データ不要	最速	アーキテクチャ (ハード制約)
FD	高	最速 (Solve) / データ不要	補間処理	アルゴリズム (離散化)

結論：物理原理の統合が精度と効率を飛躍的に向上させる

1. **物理の価値**: 純粋なデータ駆動型アプローチは物理現象の精密なモデリングには限界がある。物理法則を何らかの形で組み込むことが、精度向上の鍵となる。
2. **統合の仕方**: 物理法則の「統合の仕方」が、性能を大きく左右する。損失関数に加えるソフトな制約 (PINN) よりも、アーキテクチャに埋め込むハードな制約 (PENN) の方が、本問題においては遥かに効率的かつ高精度であった。
3. **PENNのポテンシャル**: PENNは、伝統的な数値解法に匹敵する精度をを、ニューラルネットワークの持つ柔軟性や（一度学習すれば）高速な推論能力と両立させる強力なアプローチである。
4. **最適な選択**: 究極的に、最適な手法の選択は、問題の構造に関するドメイン知識、利用可能なデータ、そして求められる性能（精度、速度）のバランスによって決定される。

